

ESTATÍSTICA APLICADA À DATA SCIENCE

SABRINA LISBOA MORAES

RELATÓRIO ANÁLISE DE DADOS E SÉRIES TEMPORAIS COM
PYTHON

Salvador, Ba
Maio, 2026.

1. Objetivo Geral:

Analisar séries temporais de dados elétricos industriais (tensão, corrente e potência) para identificar padrões de comportamento e possíveis anomalias no sistema de distribuição de energia.

1.1. Objetivos Específicos:

- Pré-processamento de Dados: Compreender a teoria e aplicar na prática (via Python e biblioteca pandas) técnicas essenciais de tratamento de dados, especificamente a normalização, a padronização e a reamostragem temporal (médias mensais);
- Visualização Analítica: Construir gráficos variados (linha, dispersão e barras) para explorar as variáveis, desenvolvendo o senso crítico para delimitar as vantagens e limitações de cada tipo de gráfico na estatística;
- Modelagem Preditiva (Regressão Linear): Treinar e testar um modelo de Machine Learning (usando Scikit-Learn) capaz de prever a potência elétrica com base na corrente e avaliar sua precisão matemática através de métricas de erro (RMSE e R^2).

2. Introdução

O cenário industrial moderno exige uma gestão eficiente do consumo e da distribuição de energia elétrica para garantir a estabilidade operacional e a redução de custos. Neste contexto, a análise de dados aliada ao Machine Learning surge como uma ferramenta indispensável para monitorar sistemas e prever comportamentos. Portanto, este relatório apresenta o estudo das variáveis elétricas (Tensão (V), Corrente (A) e Potência (W)) coletadas pelo laboratório ENERGY&ETL ao longo de três anos.

O foco principal reside na aplicação do modelo de Regressão Linear Simples, técnica estatística que busca mapear a relação linear entre uma variável independente (preditora) e uma variável dependente (alvo). No caso deste estudo, o objetivo é prever a Potência (W) a partir da Corrente (A). Para garantir a confiabilidade matemática desse modelo e das análises visuais, estruturou-se uma metodologia dividida em três fases principais: Tratamento dos dados, análise exploratória e visualização, modelagem e avaliação.

Ademais, destaca-se a relevância crucial da etapa de pré-processamento de dados. Dados brutos frequentemente apresentam discrepâncias de escala que podem enviesar as análises ou prejudicar o desempenho de algoritmos de aprendizado de máquina. Dessa forma, técnicas como a padronização e a normalização são fundamentais para homogeneizar os dados antes de qualquer modelagem matemática.

3. Descrição da Base de Dados e das Técnicas Aplicadas

3.1 Base de Dados

A base de dados utilizada consiste em registros diários de três variáveis fundamentais de consumo elétrico de uma planta industrial, coletados consecutivamente ao longo de um período de três anos:

- Tensão (V): Diferença de potencial elétrico.
- Corrente (A): Intensidade do fluxo de carga elétrica.
- Potência (W): Taxa de consumo ou transferência de energia por unidade de tempo.

A partir dos dados brutos fornecidos, foi realizada a limpeza e a organização do row destes dados. O resultado dessa etapa inicial encontra-se abaixo, na imagem 2, com a amostragem das primeiras linhas, e o antes da limpeza dos dados na imagem 1.

```

      data  tensao_V  corrente_A  potencia_W
0 2021-01-01      NaN      NaN      1107.77
1 2021-01-02     218.62      5.04      1103.99
2 2021-01-03     226.48      4.00      916.23
3 2021-01-04     235.23      5.46     1277.11
4 2021-01-05     217.66      5.17     1126.95

Linhas e colunas com valores nulos:
data          0
tensao_V      19
corrente_A     13
potencia_W     0
dtype: int64

```

Imagem 1. Conjunto dos dados **antes** do tratamento. Fonte: Autoria Própria.

```

      data  tensao_V  corrente_A  potencia_W
1 2021-01-02     218.62      5.04      1103.99
2 2021-01-03     226.48      4.00      916.23
3 2021-01-04     235.23      5.46     1277.11
4 2021-01-05     217.66      5.17     1126.95
5 2021-01-06     217.66      5.50     1193.60

A quantidade de linhas e colunas são: (1070, 4)
Não há linhas e colunas com valores nulos.

```

Imagem 2. Conjunto dos dados **depois** do tratamento. Fonte: Autoria Própria.

3.2 Técnicas de Pré-processamento

Para preparar as variáveis contínuas, aplicou-se duas técnicas de redimensionamento: a) Normalização e b) Padronização. Sem este preparo, as diferenças entre as escalas geram outliers, dificuldade no processo de leitura dos gráficos e no diagnóstico (vide a imagem 3).




Imagem 3. Conjunto dos dados **antes do pré-processamento**. Fonte: Autoria Própria.

a) Normalização (Min-Max Scaling): Transforma os dados brutos de forma que todos fiquem restritos ao intervalo fechado entre 0 e 1, ideal quando os dados não seguem uma distribuição normal.




Imagem 4. Normalização dos dados. Fonte: Autoria Própria.

b) Padronização (Z-score Standardization): Modifica os dados para que passem a ter média igual a 0 e desvio padrão igual a 1. É útil para centralizar os dados e remover o impacto de outliers em análises estatísticas mais profundas.




Imagem 5. Padronização dos dados. Fonte: Autoria Própria.

3.3 Amostragem e Divisão dos Dados

Para a análise temporal de médio prazo, utilizou-se a reamostragem mensal, calculando-se a potência média para suavizar ruídos diários e identificar padrões sazonais, como mostrado na imagem 4 logo abaixo:




Imagem 4. Média mensal das potências. Fonte: Autoria própria.

Para a construção do modelo preditivo, a base de dados foi dividida utilizando a proporção clássica da ciência de dados: 80% dos dados para o conjunto de treinamento (onde o modelo aprende a relação entre corrente e potência) e 20% dos dados para o conjunto de teste (utilizados exclusivamente para validar a precisão do modelo em dados inéditos). Para a confirmação de que realmente foi utilizada essa divisão, foi realizado o cálculo contando todas as linhas da coluna da corrente e da potência, conforme a imagem 5 a seguir:

```
Total de dados originais: 1070 linhas
---
Dados de Treino: 856 linhas (80.0%)
Dados de Teste: 214 linhas (20.0%)

Verificação de segurança:
X_train e y_train têm o mesmo tamanho? True
X_test e y_test têm o mesmo tamanho? True
```

Imagem 5. Divisão 80/20 do conjunto dos dados. Fonte: Autoria própria.

4. Representações Gráficas e Análise Comparativa

4.1. Variação da Tensão ao Longo do Tempo (Gráfico de Linha)




Imagem 6. Gráfico de Linha. Fonte: Autoria Própria.]

- **Vantagens:** O gráfico de linha é a melhor escolha para séries temporais, pois preserva a ordem cronológica e permite identificar tendências de longo prazo (crescimento ou queda) e sazonalidades (padrões que se repetem em épocas específicas).
- **Limitações:** Como há dados diários ao longo de 3 anos (mais de 1000 pontos), o gráfico apresenta muito ruído. As linhas sobem e descem intensamente e bem próximas umas das outras formando um borrão amarelo, dificultando a visualização de uma tendência suave sem o uso de médias móveis. A leitura torna-se confusa por causa do excesso de pontos oscilando rapidamente em intervalos muito curtos (ruído de alta frequência).

Análise dos Dados: De acordo com o gráfico da imagem 6, observa-se que tensão oscila predominantemente de forma constante em torno de 220V, indicando um fornecimento estacionário (sem tendência de queda ou alta a longo prazo). No entanto, nota-se a presença de outliers (pontos fora da curva), como uma queda brusca expressiva abaixo de 190V por volta de setembro de 2021, e picos isolados ultrapassando 250V na metade do ano de 2021. Essas anomalias pontuais podem indicar instabilidades momentâneas na rede elétrica ou eventos atípicos no maquinário.

4.2 Relação entre Corrente e Potência (Gráfico de Dispersão)




Imagem 7. Gráfico de Dispersão. Fonte: Autoria própria.

- **Vantagens:** Permite visualizar diretamente a correlação entre duas variáveis quantitativas. É essencial para verificar visualmente se existe um comportamento linear antes de aplicar uma regressão.
- **Limitações:** Perde a noção de tempo, impossibilitando saber quando cada evento ou medição ocorreu. Por exemplo, sabe-se que uma corrente de 5.0A gera cerca de 1100W de potência, mas o gráfico não mostra o ano e nem o mês em que isso ocorreu.
- **Análise dos Dados:** Neste gráfico, há a demonstração de uma correlação linear positiva, pois os pontos formam um agrupamento claro e denso em formato de reta ascendente. Isso comprova empiricamente o princípio elétrico de que a potência é diretamente proporcional à Corrente. Essa visualização justifica e valida com segurança a escolha do modelo de Regressão Linear Simples para este projeto, pois a relação entre as variáveis é linear.

4.3 Média Mensal da Potência (Gráfico de Barras)





Imagem 7. Gráfico de Barras. Fonte: Autoria própria.

- **Vantagens:** Muito eficaz para comparar grandezas entre categorias discretas (neste caso, os meses ou anos). Facilita a identificação visual rápida de períodos de pico ou de baixo consumo.
- **Limitações:** Não exibe a variação detalhada ou a volatilidade dos dados dentro do próprio mês. Por exemplo, um mês pode mostrar uma média de 1000W, mas o gráfico não permite saber se o consumo foi de exatos 1000W todos os dias.

Análise dos Dados: O gráfico de barras demonstra que os meses de maior consumo de potência média foram os meses de Novembro de 2021 e Janeiro de 2022, o que pode estar atrelado a períodos de maior atividade fabril. Entretanto, observa-se que o consumo de potência média mensal da planta é bastante estável e previsível, mantendo-se num platô entre 1000W e 1150W durante os três anos. Além disso, a ausência de quedas drásticas nos meses indica que a planta industrial possui um regime de operação fabril contínuo, sem paralisações sazonais longas.

4. INTERPRETAÇÃO DOS RESULTADOS DO MODELO DE REGRESSÃO

A modelagem de regressão linear simples resultou nos seguintes resultados matemáticos:



```
RESULTADOS DA REGRESSÃO LINEAR
-----
Equação: Potência = 221.34 * Corrente + (-6.67)
Inclinação (Coeficiente Angular): 221.34
Intercepto (Coeficiente Linear): -6.67
RMSE (Raiz do Erro Quadrático Médio): 50.79 W
R² (Coeficiente de Determinação): 81.18%
```

Imagem 8. Equação, RMSE e R^2 . Fonte: Autoria própria.

4.1 Análise dos Coeficientes

Inclinação (Coeficiente Angular): O valor calculado de 221.34 do coeficiente angular indica que, para cada aumento de 1 Ampere (A) na Corrente elétrica, a potência estimada da planta aumenta em aproximadamente 221.34 Watts (W).

Intercepto (Coeficiente Linear): O valor de -6.67 do coeficiente linear representa o valor teórico da potência quando a Corrente é igual a zero. Isso reflete o consumo basal residual ou pequenas perdas do sistema mesmo sem carga ativa.

4.2 Avaliação de Desempenho

Para medir a precisão das estimativas do modelo frente aos dados reais de teste, extraiu-se duas métricas de desempenho:

Erro Quadrático Médio Raiz (RMSE): O modelo apresentou um RMSE de 50.79 W. Isso significa que, em média, as previsões de potência do modelo erram por uma margem de 50.79 Watts para mais ou para menos.

Coeficiente de Determinação (R^2): O valor de R^2 obtido foi de 0.8118. Isso indica que 81,18% da variabilidade da potência é explicada de forma direta pela corrente elétrica. Os 18,82% restantes podem representar perdas de energia por calor ou pequenos erros de leitura dos sensores. Variáveis que o modelo de regressão simples (que só olha para a Corrente) não consegue explicar.

4.3 Análise do Gráfico Comparativo




Imagem 9. Gráfico Comparativo: Valores Reais vs. Previsão. Fonte: Autoria própria.

→ Neste gráfico comparativo, constata-se que a linha vermelha corta exatamente o centro da nuvem de pontos azuis em toda a sua extensão. Isso demonstra que, visualmente, a reta de regressão conseguiu capturar a tendência principal de crescimento da Potência em função da Corrente.

→ A distância vertical entre um ponto azul (o que realmente aconteceu) e a linha vermelha (o que o modelo achou que iria acontecer) representa o erro residual. Nota-se que essa faixa de erro se mantém constante ao longo de todo o gráfico. Essa distância média corresponde justamente ao RMSE calculado (50.79 W).

→ A proximidade aglomerada dos pontos azuis ao redor da linha vermelha reflete diretamente o Coeficiente de Determinação (R^2 de 0.8118). Como os pontos estão concentrados, comprova-se que o modelo consegue explicar a grande maioria das variações no consumo de energia.

O modelo não apresenta vícios graves. A precisão se mantém estável desde as marcações de 3.5A até as de 6.0A. No dia a dia da planta industrial, isso significa que a equipe de engenharia pode usar a equação da Regressão Linear Simples com alto grau de confiança para estimar a carga de potência do sistema sob diferentes regimes de corrente.

5. Conclusão e Recomendações para Aplicações Futuras

A partir deste relatório técnico, o estudo conseguiu atingir os objetivos propostos ao evidenciar a dinâmica das variáveis elétricas por meio de dados obtidos pelo laboratório ENERGY&ETL. As etapas de pré-processamento foram fundamentais para garantir a integridade e a qualidade da análise estrutural. A aplicação de técnicas de normalização e padronização garantiu a estabilidade matemática do algoritmo, enquanto a reamostragem mensal permitiu isolar o ruído diário e visualizar o perfil de consumo macro da indústria com clareza. Além disso, as análises gráficas, especialmente por meio do gráfico de dispersão, foram decisivas para validar a forte correlação linear positiva entre as variáveis escolhidas, justificando a adoção do modelo preditivo linear.

O modelo de Regressão Linear Simples apresentou uma performance sólida, caracterizada por um baixo índice de erro (RMSE) de 50.79 W e um elevado coeficiente de determinação (R^2) de 0.8118. Além disso, a equação da reta gerada consolidou-se como uma ferramenta preditiva confiável e de fácil implementação direta em sistemas de controle operacional. Tudo isso comprova que monitorar a corrente é um método altamente confiável e matematicamente viável para prever demandas de potência no sistema de distribuição.

Como recomendações para aplicações futuras, sugere-se:

1. Expansão do modelo atual para uma Regressão Linear Múltipla, inserindo a variável da Tensão (V) juntamente com a Corrente (A) para verificar se a combinação de ambas reduz ainda mais o erro residual (RMSE).
2. A implementação de algoritmos de detecção de anomalias baseados no modelo treinado. Desvios significativos onde a potência real medida fique muito acima da linha de predição calculada para aquela corrente podem sinalizar falhas de isolamento, superaquecimento ou sobrecarga em componentes das plantas industriais.

6. Referências

GRUS, J. Data science do zero: primeiros princípios com Python. Rio de Janeiro: Alta Books, 2021. E-book.

MORETTIN, P. A.; TOLOI, C. M. C. Análise de séries temporais: modelos lineares univariados. 3. ed. São Paulo: Blucher, 2018.